Arquitectura de Referencia:

Diseñando una arquitectura de análisis moderna mediante Azure Databricks

Esta solución describe los principios y componentes clave de las arquitecturas de datos modernas. Azure Databricks constituye el núcleo de la solución. Esta plataforma funciona a la perfección con otros servicios, como Azure Data Lake Storage, Microsoft Fabric y Power BI.

Arquitectura

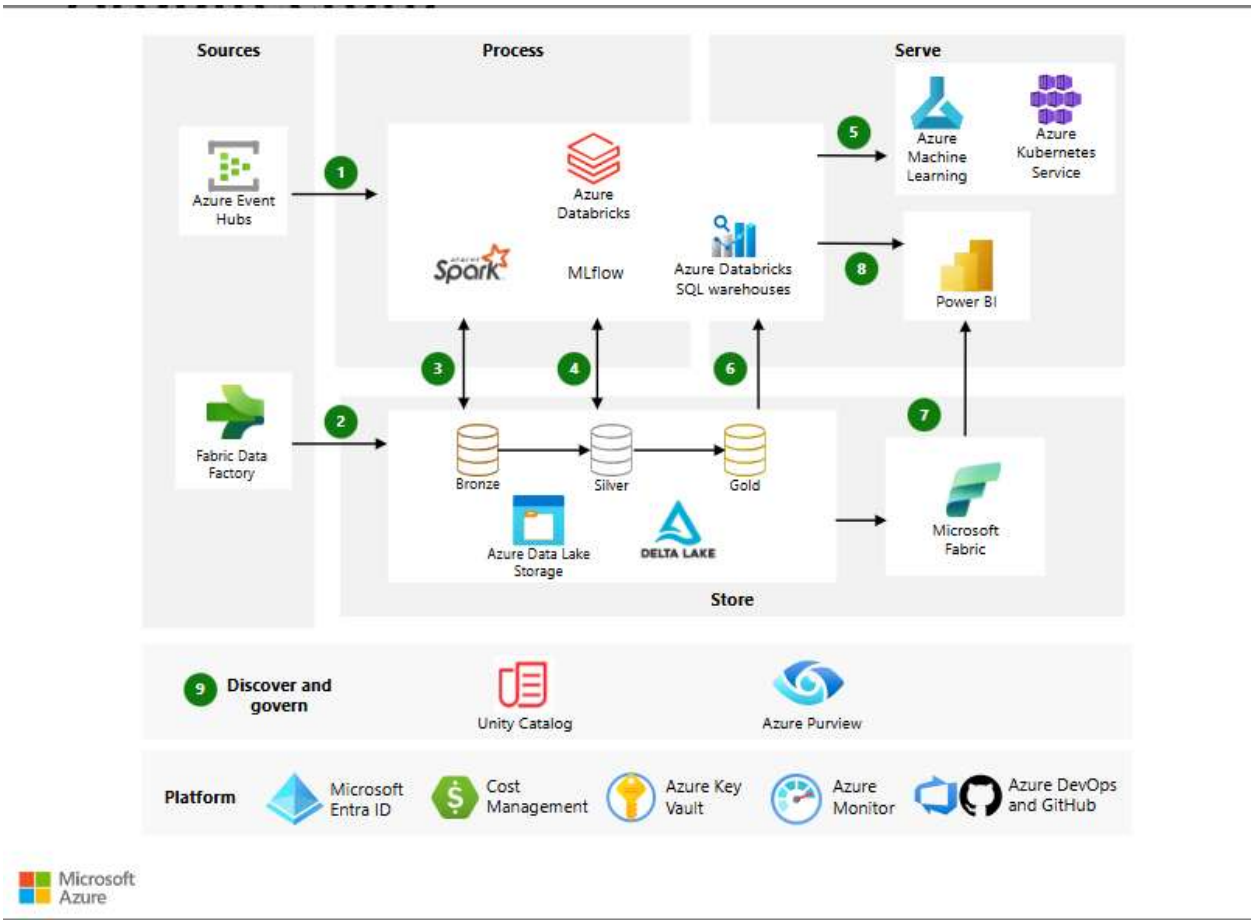

Flujo de datos

1. Azure Databricks ingiere datos de transmisión sin procesar desde Azure Event Hubs mediante Delta Live Tables.
2. Fabric Data Factory carga datos de lotes sin procesar en Data Lake Storage.
3. Para el almacenamiento de datos:

- Data Lake Storage alberga todo tipo de datos, incluyendo datos estructurados, no estructurados y parcialmente estructurados. También almacena datos por lotes y en streaming.
- Delta Lake constituye la capa depurada del lago de datos. Almacena los datos refinados en un formato de código abierto.
- Azure Databricks funciona bien con una arquitectura de medallón que organiza los datos en capas:
    - Capa de bronce: contiene datos sin procesar.
    - Capa de plata: contiene datos limpios y filtrados.
    - Capa dorada: almacena datos agregados que son útiles para el análisis empresarial.

4. La plataforma analítica ingiere datos de distintas fuentes de lotes y streaming. Los científicos de datos utilizan estos datos para tareas como:
    - Preparación de datos.
    - Exploración de datos.
    - Preparación del modelo.
    - Entrenamiento de modelos.

MLflow gestiona el seguimiento de parámetros, métricas y modelos en ejecuciones de código de ciencia de datos. Las posibilidades de codificación son flexibles:

- El código puede estar en SQL, Python, R y Scala.
- El código puede utilizar bibliotecas y marcos de código abierto populares como Koalas, Pandas y scikit-learn, que están preinstalados y optimizados.
- Los usuarios pueden optimizar el rendimiento y el costo mediante el uso de opciones de cómputo de nodo único y de nodos múltiples.

5. Los modelos de aprendizaje automático están disponibles en los siguientes formatos:
    - Azure Databricks almacena información sobre los modelos en el Registro de Modelos de MLflow . Este registro facilita el acceso a los modelos mediante API por lotes, streaming y REST.
    - La solución también puede implementar modelos en servicios web de Azure Machine Learning o Azure Kubernetes Service (AKS).

6. Los servicios que trabajan con los datos se conectan a una única fuente de datos subyacente para garantizar la coherencia. Por ejemplo, se pueden ejecutar consultas SQL en el lago de datos mediante almacenes de SQL de Azure Databricks. Este servicio:
    - Proporciona un editor y catálogo de consultas, historial de consultas, panel de control básico y alertas.
    - Utiliza seguridad integrada que incluye permisos a nivel de fila y permisos a nivel de columna.
    - Utiliza un motor Delta impulsado por Photon para mejorar el rendimiento .
7. Puede replicar conjuntos de datos de referencia del catálogo de Unity de Azure Databricks en Fabric. Use la replicación de Azure Databricks en Fabric para una integración sencilla sin necesidad de mover ni replicar datos.
8. Power BI genera informes y paneles analíticos e históricos desde la plataforma de datos unificada. Este servicio utiliza las siguientes características cuando funciona con Azure Databricks:
    - Un conector de Azure Databricks integrado para visualizar los datos subyacentes.
    - Controladores de conectividad de base de datos Java optimizados y conectividad de base de datos abierta.
    - Puede usar Direct Lake con la duplicación de Azure Databricks en Fabric para cargar sus modelos semánticos de Power BI para consultas de mayor rendimiento.
9. La solución utiliza Unity Catalog y servicios de Azure para colaboración, rendimiento, confiabilidad, gobernanza y seguridad:
    - El catálogo de Unity de Azure Databricks proporciona control de acceso centralizado, auditoría, linaje y capacidades de descubrimiento de datos en todos los espacios de trabajo de Azure Databricks.
    - Microsoft Purview proporciona servicios de descubrimiento de datos, clasificación de datos confidenciales y conocimientos de gobernanza en todo el patrimonio de datos.
    - Azure DevOps ofrece integración continua e implementación continua (CI/CD) y otras funciones de control de versiones integradas.
    - Azure Key Vault le ayuda a administrar de forma segura secretos, claves y certificados.

- Microsoft Entra ID y el aprovisionamiento del Sistema para la Administración de Identidades entre Dominios (SCIM) proporcionan inicio de sesión único para usuarios y grupos de Azure Databricks. Azure Databricks admite el aprovisionamiento automatizado de usuarios con Microsoft Entra ID para:
    - Crear nuevos usuarios y grupos.
    - Asignar a cada usuario un nivel de acceso.
    - Eliminar usuarios y negarles el acceso.
- Azure Monitor recopila y analiza la telemetría de los recursos de Azure. Al identificar problemas de forma proactiva, este servicio maximiza el rendimiento y la confiabilidad.
- Microsoft Cost Management proporciona servicios de gobernanza financiera para cargas de trabajo de Azure.

Componentes

Esta solución utiliza los siguientes componentes.

Componentes principales

- Azure Databricks es una plataforma de análisis de datos que utiliza clústeres Spark para procesar grandes flujos de datos. Limpia y transforma datos no estructurados y los combina con datos estructurados. También puede entrenar e implementar modelos de aprendizaje automático. En esta arquitectura, Azure Databricks actúa como la herramienta central para la ingesta, el procesamiento y la distribución de datos. Proporciona un entorno unificado para gestionar todo el ciclo de vida de los datos.
- Los almacenes de SQL de Azure Databricks son recursos de cómputo que se pueden usar para consultar y explorar datos en Azure Databricks. En esta arquitectura, se pueden usar puntos de conexión de SQL para conectarse directamente a los datos desde Power BI.
- Delta Live Tables de Azure Databricks es un marco declarativo para crear canalizaciones de procesamiento de datos fiables, fáciles de mantener y de probar. En esta arquitectura, Delta Live Tables ayuda a definir las transformaciones que se realizarán en los datos. También ayuda a gestionar la orquestación de tareas, la administración de clústeres, la monitorización, la calidad de los datos y el control de errores en Azure Databricks.

- Microsoft Fabric es una plataforma integral de análisis y datos para organizaciones que necesitan una solución unificada. La plataforma ofrece servicios como ingeniería de datos, fábrica de datos, ciencia de datos, inteligencia en tiempo real, almacén de datos y bases de datos. Esta arquitectura replica las tablas del catálogo de Unity en Fabric y utiliza Direct Lake en Power BI para un mejor rendimiento.
- Data Factory en Microsoft Fabric es una moderna plataforma de integración de datos que permite ingerir, preparar y transformar datos de un amplio conjunto de orígenes de datos en Fabric. Esta arquitectura utiliza conectores integrados con varios orígenes de datos para una rápida ingestión en Data Lake Storage o OneLake. Posteriormente, Azure Databricks recupera y transforma los datos por lotes.
- Event Hubs es una plataforma de streaming de big data totalmente administrada. Como plataforma como servicio, ofrece capacidades de ingesta de eventos. Esta arquitectura utiliza Event Hubs para la transmisión de datos. Azure Databricks puede conectarse a estos datos y procesarlos mediante Spark Streaming o Delta Live Tables.
- Data Lake Storage es un lago de datos escalable y seguro para análisis de alto rendimiento. Gestiona múltiples petabytes de datos y admite cientos de gigabits de rendimiento. Data Lake Storage puede almacenar datos estructurados, parcialmente estructurados y no estructurados. Esta arquitectura utiliza Data Lake Storage para almacenar datos por lotes y en streaming.
- El aprendizaje automático es un entorno basado en la nube que le ayuda a crear, implementar y administrar soluciones de análisis predictivo. Mediante estos modelos, puede pronosticar comportamientos, resultados y tendencias. En esta arquitectura, el aprendizaje automático utiliza datos que Azure Databricks transforma para entrenar e inferir modelos.
- AKS es un servicio de Kubernetes de alta disponibilidad, seguro y totalmente administrado. AKS facilita la implementación y la administración de aplicaciones en contenedores. En esta arquitectura, AKS aloja modelos de aprendizaje automático en un entorno contenedorizado para una inferencia escalable.
- Delta Lake es una capa de almacenamiento que utiliza un formato de archivo abierto. Esta capa se ejecuta sobre soluciones de almacenamiento en la nube como Data Lake Storage. Delta Lake admite el control de versiones, la reversión y las transacciones para actualizar, eliminar y fusionar datos. En esta arquitectura, Delta Lake funciona como el formato de archivo principal para escribir y leer datos de Data Lake Storage.
- MLflow es una plataforma de código abierto para gestionar el ciclo de vida del aprendizaje automático. Sus componentes supervisan los modelos de aprendizaje

automático durante el entrenamiento y la operación. En esta arquitectura, similar al aprendizaje automático, puede usar MLflow en Azure Databricks para gestionar su ciclo de vida. Entrene e infiera modelos utilizando los datos del Catálogo de Unity que transformó en Azure Databricks.

Componentes de informes y gobernanza

- El Catálogo de Unity de Azure Databricks proporciona funciones centralizadas de control de acceso, auditoría, linaje y descubrimiento de datos en los espacios de trabajo de Azure Databricks. En esta arquitectura, el Catálogo de Unity funciona como la herramienta principal de Azure Databricks para administrar y proteger el acceso a los datos.
- Power BI es un conjunto de servicios de software y aplicaciones. Estos servicios crean y comparten informes que conectan y visualizan fuentes de datos independientes. Junto con Azure Databricks, Power BI permite determinar la causa raíz y analizar datos sin procesar. Esta arquitectura utiliza Power BI para crear paneles e informes que ofrecen información sobre los datos que procesan Azure Databricks y Fabric.
- Microsoft Purview gestiona datos locales, multicloud y de software como servicio (SaaS). Este servicio de gobernanza mantiene mapas del panorama de datos. Sus funciones incluyen el descubrimiento automatizado de datos, la clasificación de datos confidenciales y el linaje de datos. Esta arquitectura utiliza Microsoft Purview para analizar y rastrear los datos que se incorporan en Unity Catalog, Fabric, Power BI y Data Lake Storage.
- Azure DevOps es una plataforma de orquestación de DevOps. Este SaaS proporciona herramientas y entornos para crear, implementar y colaborar en aplicaciones. Esta arquitectura utiliza Azure DevOps para automatizar la implementación de la infraestructura de Azure. También puede usar GitHub para la automatización y el control de versiones del código de Azure Databricks, lo que mejora la colaboración, el seguimiento de cambios y la integración con las canalizaciones de CI/CD.
- Key Vault almacena y controla el acceso a secretos, como tokens, contraseñas y claves API. Key Vault también crea y controla claves de cifrado y administra certificados de seguridad. Esta arquitectura utiliza Key Vault para almacenar claves de firma de acceso compartido de Data Lake Storage. Estas claves se utilizan posteriormente en Azure Databricks y otros servicios para la autenticación.
- Microsoft Entra ID ofrece servicios de gestión de identidades y acceso basados en la nube. Estas funciones permiten a los usuarios iniciar sesión y acceder a los recursos. Esta

arquitectura utiliza Microsoft Entra ID para autenticar y autorizar usuarios y servicios en Azure.

- SCIM permite configurar el aprovisionamiento de la cuenta de Azure Databricks mediante el ID de Microsoft Entra. Esta arquitectura utiliza SCIM para administrar los usuarios que acceden a los espacios de trabajo de Azure Databricks.
- Azure Monitor recopila y analiza datos de entornos y recursos de Azure. Estos datos incluyen telemetría de aplicaciones, como métricas de rendimiento y registros de actividad. Esta arquitectura utiliza Azure Monitor para supervisar el estado de los recursos informáticos en Azure Databricks y Machine Learning, así como otros componentes que envían registros a Azure Monitor.
- La Gestión de Costos le ayuda a gestionar los gastos en la nube. Mediante presupuestos y recomendaciones, este servicio organiza los gastos y le muestra cómo reducirlos. Esta arquitectura utiliza la Gestión de Costos para supervisar y controlar el coste de toda la solución.

Detalles del escenario

Arquitecturas de datos modernas:

- Unifique las cargas de trabajo de datos, análisis e inteligencia artificial.
- Ejecute de manera eficiente y confiable a cualquier escala.
- Proporcione información a través de paneles de análisis, informes operativos o análisis avanzados.

Esta solución describe una arquitectura de datos moderna que logra estos objetivos. Azure Databricks constituye el núcleo de la solución. Esta plataforma funciona a la perfección con otros servicios. Juntos, estos servicios proporcionan una solución que:

- Simple: el análisis unificado, la ciencia de datos y el aprendizaje automático simplifican la arquitectura de datos.
- Abierto: La solución es compatible con código fuente abierto, estándares abiertos y frameworks abiertos. También funciona con entornos de desarrollo integrados (IDE), bibliotecas y lenguajes de programación populares. Gracias a sus conectores y API nativos, la solución también es compatible con una amplia gama de otros servicios.
- Colaborativo: Ingenieros, científicos y analistas de datos colaboran con esta solución. Pueden usar cuadernos colaborativos, IDE, paneles y otras herramientas para acceder y analizar datos subyacentes comunes.

Casos de uso potenciales

El sistema que Swiss Re Group desarrolló para su división de reaseguros de daños y responsabilidad civil inspiró esta solución. Además del sector asegurador, cualquier área que trabaje con big data o aprendizaje automático también puede beneficiarse de esta solución. Algunos ejemplos incluyen:

- El sector energético.
- Comercio minorista y electrónico.
- Banca y finanzas.
- Medicina y atención sanitaria.

🔎 **¿Dónde están los componentes en el stack?**

✅ **1. Frontend (capa de presentación):**

Es la capa que usan los usuarios finales para interactuar con los datos y generar valor.

- **Power BI** → Herramienta de visualización y análisis interactivo.
- Dashboards e informes accesibles vía web o dispositivos móviles.
  (Aquí es donde los analistas de negocio, gerentes o docentes verán los reportes, gráficas y KPIs.)

✅ **2. Backend (capa lógica de negocio):**

Es la capa que procesa, limpia, transforma y prepara los datos para el análisis.

- **Azure Databricks** → Procesa datos con clústeres Spark, ejecuta código en Python, R, SQL o Scala.
- **Delta Live Tables** → Orquesta pipelines de datos y aplica transformaciones.
- **Microsoft Fabric / Data Factory** → Orquestación de flujos de datos por lotes y en streaming.
- **MLflow y modelos de Machine Learning** → Gestionan entrenamiento y despliegue de modelos predictivos.

✅ **3. Base de datos / almacenamiento de datos:**

Es la capa donde los datos se guardan en diferentes niveles de limpieza y granularidad.

- **Azure Data Lake Storage** → Almacena datos crudos y procesados (estructurados, no estructurados).
- **Delta Lake** → Capa transaccional para datos limpios (bronze, silver, gold).
- **Catálogo de Unity** → Metadatos, control de acceso, linaje y auditoría de datos.

✅ **4. Infraestructura (capa de soporte y servicios):**

Proporciona los recursos físicos y virtuales para que todo funcione.

- **Azure Monitor, Key Vault, Microsoft Entra ID (SCIM)** → Seguridad, autenticación y gestión de usuarios.
- **Azure Kubernetes Service (AKS)** → Infraestructura para desplegar modelos ML a escala.
- **Azure DevOps** → Infraestructura para CI/CD y gestión de versiones.
- **Event Hubs** → Plataforma de ingesta de datos en tiempo real.

📊 **¿Hay herramientas analíticas?**

✅ Sí:

- **Power BI** (BI y visualización)
- **MLflow** (gestión de ciclo de vida de modelos)
- **Databricks SQL Warehouses** (consultas y análisis SQL)

🔗 **¿Hay plataformas de integración?**

✅ Sí:

- **Microsoft Fabric / Data Factory** → Integración de datos desde múltiples fuentes.
- **Unity Catalog** → Integra metadatos y seguridad entre servicios.
- **Event Hubs** → Integración en tiempo real para flujos de datos.

💼 **¿Qué aplicaciones de negocio se pueden dar al caso de infraestructura?**

Esta arquitectura es muy flexible y puede aplicarse a distintos sectores. Algunos ejemplos:

- **Educación:** Analizar datos de estudiantes, plataformas virtuales, asistencia, resultados.
- **Salud:** Procesar datos de pacientes, sensores médicos, predicción de diagnósticos.
- **Comercio electrónico:** Analizar ventas, inventarios, recomendaciones personalizadas.
- **Energía:** Monitorear consumo en tiempo real, detectar fallas en infraestructura crítica.
- **Banca y finanzas:** Modelos de riesgo, prevención de fraude, análisis de crédito.

📝 **Actividad práctica sugerida:**

Analiza la arquitectura de Azure Databricks

1. Identifica en el diagrama los componentes de **almacenamiento**, **procesamiento**, **análisis** y **visualización**.
2. Explica cómo estos servicios trabajan juntos siguiendo las capas bronce, plata y oro.
3. Propón una mejora o un servicio adicional que podrías integrar para tu contexto (educación, negocio, salud, etc.).

📌 **Evaluación o reflexión:**

- ¿Cómo se compara esta arquitectura con la definición de stack digital estudiada?
- ¿Qué ventajas ves al usar servicios integrados en la nube frente a un stack local?